

Вычислительные методы линейной алгебры. Нестационарные итерационные методы решения систем линейных алгебраических уравнений

Чеховской Игорь Сергеевич

Стационарные:

- метод Рундсона
- Метод Якоби
- Метод Гаусса-Зейделя
- Метод релаксации

Нестационарные:

- Наискорейший градиентный спуск
- Метод сопряжённых градиентов
- Метод бисопряжённых градиентов
- Стабилизированный метод бисопряжённых градиентов

Нестационарные итерационные методы: обобщение процесса Ричардсона

Рассмотрим обобщение итерационного процесса Ричардсона с переменным параметром τ_k :

$$x^{(k+1)} \leftarrow x^{(k)} - \tau_k(Ax^{(k)} - b), \quad k = 0, 1, 2, \dots$$

Матричное обобщение:

$$x^{(k+1)} \leftarrow x^{(k)} - \Lambda_k(Ax^{(k)} - b), \quad k = 0, 1, 2, \dots,$$

где $\{\Lambda_k\}_{k=0}^{\infty}$ — некоторая последовательность матриц. Условие сходимости этого метода зависит от выбора Λ_k и начального приближения $x^{(0)}$.

Полуитерационные методы Чебышёва (Chebyshev semi-iterative methods) позволяют ускорить метод Рундсона и обеспечивают оптимальный выбор параметров τ_k :

$$x^{(k+1)} \leftarrow x^{(k)} - \tau_k(Ax^{(k)} - b),$$

где τ_k выбираются исходя из полинома Чебышёва k -й степени и зависят от оценки спектрального интервала $[\mu, M]$ симм. положит. опред. матрицы A :

- при малом спектральном интервале $[M/\mu \approx 1]$ метод быстро сходится.
- при высокой обусловленности A (большое M/μ) требуется больше итераций.

Метод верхней релаксации (Successive Overrelaxation, SOR) применяется к решению системы $Ax = b$ и использует параметр релаксации ω_k , который может изменяться на каждом шаге итерации.

Итерационная формула имеет вид:

$$x_i^{(k+1)} \leftarrow (1 - \omega_k)x_i^{(k)} + \frac{\omega_k}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)} \right).$$

- Параметр ω_k управляет темпом продвижения по направлению невязки.
- Его изменение позволяет ускорить сходимость или стабилизировать процесс.
- Последовательность $\{\omega_k\}$ может быть задана априори или адаптивно рассчитываться по ходу итераций.
- Метод применяется для разреженных и симметричных матриц, а также в схемах численного решения дифференциальных уравнений.

Другой путь построения нестационарных итерационных методов — использование вариационных принципов.

Идея: решить систему $Ax = b$ можно как задачу оптимизации — найти минимум нормы невязки:

$$Ax = b \Leftrightarrow \min \|Ax - b\|.$$

Наиболее естественно использовать евклидову норму, что эквивалентно минимизации квадрата нормы:

$$\min \|Ax - b\|^2 = \min (Ax - b, Ax - b).$$

Это линейная задача наименьших квадратов.

Теорема. Вектор $x^* \in \mathbb{R}^n$ является решением СЛАУ $Ax = b$ с симм. полож. опр. матр. $A \Leftrightarrow$ он доставляет минимум функционалу энергии $\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$. Иными словами:

$$\text{решение } Ax = b \Leftrightarrow \text{нахождение } \min \Psi(x).$$

Доказательство. Если A — симметричная положительно-определённая матрица, то решение x^* системы $Ax = b$ существует и единственно.

Введём энергетическую норму:

$$\|x\|_A = \sqrt{(Ax, x)}.$$

Из единственности x^* следует: x — решение $Ax = b \Leftrightarrow x - x^* = 0 \Leftrightarrow \|x - x^*\|_A = 0$.

То есть:

$$x \text{ есть решение } Ax = b \Leftrightarrow \frac{1}{2}\|x - x^*\|_A^2 = 0.$$

Преобразуем выражение:

$$\begin{aligned}\frac{1}{2}\|x - x^*\|_A^2 &= \frac{1}{2}(A(x - x^*), x - x^*) = \\&= \frac{1}{2}(Ax, x) - \frac{1}{2}(Ax^*, x) - \frac{1}{2}(Ax, x^*) + \frac{1}{2}(Ax^*, x^*) = \\&= \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}\|x^*\|_A^2 = \Psi(x) + \frac{1}{2}\|x^*\|_A^2.\end{aligned}$$

Следовательно, x — точка минимума $\Psi(x)$ тогда и только тогда, когда x — решение $Ax = b$. ■

Следствие. $\Psi(x)$ достигает минимума в точке x^* и отличается от $\frac{1}{2}\|x - x^*\|_A^2$ лишь на константу. Поэтому:

$$\Psi(x) = \frac{1}{2}\|x - x^*\|_A^2 + \text{const.}$$

Этот факт будет неоднократно использоваться далее.

Поскольку A – симм. матрица, то ортогональным преобразованием подобия она может быть приведена к диагональной матрице:


$$A = Q^T D Q,$$

где Q ортогональна, $D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$, а λ_i — с. з. матрицы A , причём все $\lambda_i > 0$ в силу положительной определённости A . Подставляя это представление в выражение для функционала энергии $\Psi(x)$, получим

$$\begin{aligned}\Psi(x) &= \frac{1}{2}(Q^T D Q x, x) - (b, x) = \frac{1}{2}(D(Qx), Qx) - (Qb, Qx) \\ &= \frac{1}{2}(Dy, y) - (Qb, y) = \frac{1}{2} \sum_{i=1}^n \lambda_i y_i^2 - \sum_{i=1}^n (Qb)_i y_i,\end{aligned}$$

где обозначено $y = Qx$.

График функционала энергии: параболоид с линиями уровня — эллипсами, центр которых — точное решение.




Чем больше обусловленность матрицы A , тем сильнее сплющены эллипсоиды уровня, так что для плохообусловленных СЛАУ решение находится на дне длинного и узкого "оврага".

Метод спуска: постановка задачи

Рассмотрим задачу минимизации функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$:

$$f(x) \geq f(x^*) = \min_{x \in \mathbb{R}^n} f(x) \quad \text{для всех } x \in \mathbb{R}^n.$$



Глобальные и локальные минимумы функции.

- x^* — точка глобального минимума.
- Функция f называется *целевой функцией*.
- Типичные алгоритмы — построение последовательности $\{x^{(k)}\}$:

$$\lim_{k \rightarrow \infty} f(x^{(k)}) = \min_{x \in \mathbb{R}^n} f(x).$$

Метод спуска: шаг алгоритма

Пусть известно приближение $x^{(k)}$ к точке минимума.

- Выбираем направление спуска s , в котором f убывает.
- Затем выбираем шаг τ и делаем переход:

$$x^{(k+1)} \leftarrow x^{(k)} + \tau s.$$

- Требование:

$$f(x^{(k+1)}) < f(x^{(k)}).$$

Выбор шага τ вдоль уже выбранного направления s называют **line search**.

Т. к. при фиксированном направлении s неизвестной остается только одна величина τ , такой выбор шага также называют **одномерным поиском**.

Выбор s и τ критически влияет на наличие сходимости и её скорость.

Если целевая функция имеет более одного локального экстремума, то метод спуска может сходиться к какому-нибудь одному из них, который не обязательно является глобальным.

Тогда предпринимают многократный запуск метода спуска из различных начальных точек ("мультистарт"), применяют другие модификации, которые помогают преодолеть локальный характер метода спуска.

Метод спуска: идея наискорейшего спуска

Но для матрицы $A = A^T > 0$ минимум функционала энергии $\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$ только один — глобальный.

Наискорейший спуск:

- выбираем направление спуска s ;
- шаг τ выбирается **точным line search**, то есть точной минимизацией $\Psi(x^{(k)} + \tau s)$ по τ :

$$\tau_k = \arg \min_{\tau} \Psi(x^{(k)} + \tau s).$$

То есть при фиксированном направлении s мы минимизируем функцию одной переменной τ .

$$\begin{aligned} \Psi(x^{(k)} + \tau s) &= \frac{1}{2}(A(x^{(k)} + \tau s), x^{(k)} + \tau s) - (b, x^{(k)} + \tau s) \\ &= \frac{1}{2}(Ax^{(k)}, x^{(k)}) + \tau(Ax^{(k)}, s) + \frac{1}{2}\tau^2(As, s) - (b, x^{(k)}) - \tau(b, s). \end{aligned}$$

При дифф-ии по τ не зависящие от него слагаемые исчезнут, и получим

$$\begin{aligned} \frac{d}{d\tau} \Psi(x^{(k)} + \tau s) &= (Ax^{(k)}, s) + \tau(As, s) - (b, s) \\ &= \tau(As, s) + (Ax^{(k)} - b, s) = \tau(As, s) + (r^{(k)}, s), \end{aligned}$$

где $r^{(k)} := Ax^{(k)} - b$ — невязка текущего приближения к решению.

Таким образом, в точке экстремума по τ условие

$$\frac{d}{d\tau} \Psi(x^{(k)} + \tau s) = 0$$

необходимо влечёт

$$\tau = -\frac{(r, s)}{(As, s)}.$$

Минимум действительно достигается, так как

$$\frac{d^2}{d\tau^2} \Psi(x^{(k)} + \tau s) = (As, s) > 0$$

в силу положительной определённости матрицы A .

Градиентный спуск: определение градиента функционала энергии

Если целевая функция $f(x)$ дифф-ма, то направление её наибольшего убывания в т. $x^{(k)}$ противоположно направлению вектора градиента

$$\nabla f(x) := f'(x^{(k)}) = \left(f'_1(x^{(k)}), f'_2(x^{(k)}), \dots, f'_n(x^{(k)}) \right)^\top.$$

Это наблюдение даёт начало одному из распространённых вариантов метода спуска для минимизации функций — **методу градиентного спуска**, в котором направлением спуска берётся “антиградиент”, т.е. вектор $-f'(x^{(k)})$, а очередной шаг выполняется по формуле

$$x^{(k+1)} \leftarrow x^{(k)} - \tau_k f'(x^{(k)}),$$

для некоторого $\tau_k \in \mathbb{R}$. Какой вид имеет градиентный спуск для минимизации функционала энергии

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)?$$

Градиентный спуск: определение градиента функционала энергии

Вычислим его градиент по компоненте x_l :

$$\frac{\partial \Psi(x)}{\partial x_l} = \frac{\partial}{\partial x_l} \left(\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \right) = \sum_{j=1}^n a_{lj} x_j - b_l,$$

где $l = 1, 2, \dots, n$. Т. о., градиент можно записать в векторной форме:

$$\nabla \Psi(x) = \left(\frac{\partial \Psi(x)}{\partial x_1}, \frac{\partial \Psi(x)}{\partial x_2}, \dots, \frac{\partial \Psi(x)}{\partial x_n} \right)^T = Ax - b,$$

т. е. градиент функционала Ψ равен невязке решаемой системы линейных уравнений в рассматриваемой точке.

Формула обновления градиентного спуска:

$$x^{(k+1)} \leftarrow x^{(k)} - \tau \nabla \Psi(x^{(k)}), \quad k = 0, 1, 2, \dots$$

Это эквивалентно методу Ричардсона:

$$x^{(k+1)} \leftarrow x^{(k)} - \tau (Ax^{(k)} - b).$$

Таким образом, метод градиентного спуска с постоянным шагом τ совпадает с итерационной схемой Ричардсона.

Для метода градиентного спуска с постоянным шагом его трактовка как метода Ричардсона позволяет выбрать шаг $\tau_k = \text{const}$, который наверняка обеспечивает сходимость процесса.

Пусть μ и M — нижняя и верхняя границы спектра симм. положит. определенной матрицы A . Тогда для сходимости итерационного процесса шаг τ должен быть выбран как:

$$\tau = \tau_k = \frac{2}{M + \mu}.$$

Наискорейший градиентный спуск

Можно искать τ_k наибольшим возможным, обеспечивающим убывание функционала Ψ вдоль выбранного направления спуска по антиградиенту. При этом получается **метод наискорейшего градиентного спуска (steepest descent algorithm)**, теория которого была разработана в конце 40-х годов XX века Л.В. Канторовичем.

Выражение для шага

$$\tau_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}, \quad r^{(k)} := Ax^{(k)} - b.$$

```
k ← 0 ;  
выбираем начальное приближение  $x^{(0)}$  ;  
DO WHILE ( метод не сошёлся )  
     $r^{(k)} \leftarrow Ax^{(k)} - b$  ;  
     $\tau_k \leftarrow \frac{\|r^{(k)}\|_2^2}{\langle Ar^{(k)}, r^{(k)} \rangle}$  ;  
     $x^{(k+1)} \leftarrow x^{(k)} - \tau_k r^{(k)}$  ;  
    k ← k + 1 ;  
END DO
```

Наискорейший градиентный спуск: теорема о сходимости

Теорема. Если A – симметричная положительно определённая матрица, то метод наискорейшего спуска сходится к решению x^* системы уравнений $Ax = b$ из любого начального приближения $x^{(0)}$, и скорость этой сходимости оценивается неравенством

$$\|x^{(k)} - x^*\|_A \leq \left(\frac{M - \mu}{M + \mu} \right)^k \|x^{(0)} - x^*\|_A, \quad k = 0, 1, 2, \dots,$$

где μ , M – нижняя и верхняя границы спектра матрицы A .

Идея доказательства (сравнение с методом Ричардсона):

- Метод наискорейшего спуска минимизирует $\Psi(x)$ на каждом шаге.
- Сравним с методом Ричардсона с постоянным шагом $\tau = 2/(M + \mu)$.
- Тогда погрешность $\|x^{(k)} - x^*\|_A$ у наискорейшего метода не хуже, чем у Ричардсона:

$$\|x^{(k)} - x^*\|_A \leq \left(\frac{M - \mu}{M + \mu} \right)^k \|x^{(0)} - x^*\|_A.$$

Наискорейший градиентный спуск: геометрическая иллюстрация

- Градиент $\nabla\Psi(x)$ ортогонален уровням $\Psi(x)$:

если $x_0 + \varepsilon$ лежит на уровне $\Psi(x) = \Psi(x_0)$, то


$$0 = \Psi(x_0 + \varepsilon) - \Psi(x_0) = (\nabla\Psi(x_0), \varepsilon) + o(\|\varepsilon\|).$$

Поэтому

$$\left(\nabla\Psi(x_0), \frac{\varepsilon}{\|\varepsilon\|} \right) = o(1), \quad \|\varepsilon\| \rightarrow 0,$$

и в пределе $\nabla\Psi(x_0)$ ортогонален касательной к линии уровня.

- Шаги метода идут по направлению $-\nabla\Psi(x)$, до касания уровня.
- В результате траектория – ломаная с перпендикулярными отрезками.



Градиентный спуск: применение в нейронных сетях

В нейронных сетях минимизируют функционал ошибки

$$Q(w) \rightarrow \min_w,$$

где w — набор всех весов модели.

- Градиентный спуск имеет вид

$$w^{(k+1)} = w^{(k)} - \tau_k \nabla Q(w^{(k)}).$$

- При большом числе данных полный градиент считать дорого.
- Поэтому на практике часто используют **стохастический градиентный спуск** (mini-batch):

$$w^{(k+1)} = w^{(k)} - \tau_k \nabla Q_{B_k}(w^{(k)}),$$

где B_k — текущий мини-батч, то есть часть обучающей выборки.

- Идея остается той же: двигаться в направлении убывания функционала, но направление вычисляется лишь приближенно.
- В отличие от задачи минимизации функционала энергии

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

для $A = A^T > 0$, ф-я $Q(w)$ в нейросетях обычно невыпукла, поэтому гарантии нахождения глобального минимума, вообще говоря, нет.

Метод сопряженных направлений: переход от наискорейшего спуска

При точном выборе шага вдоль направления спуска (**exact line search**) в методе наискорейшего спуска новый градиент ортогонален предыдущему направлению спуска.

Так как в методе наискорейшего спуска направление равно антиградиенту, то антиградиенты у соседних шагов оказываются взаимно перпендикулярными.

Для квадратичного функционала это то же самое, что ортогональность соседних невязок:

$$(r^{(k+1)}, r^{(k)}) = 0, \quad r^{(k)} = Ax^{(k)} - b.$$

Для функционала энергии

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

естественная геометрия определяется матрицей A .

Поэтому обычная евклидова ортогональность

$$(r^{(k+1)}, r^{(k)}) = 0$$



сама по себе не гарантирует, что новый шаг не изменит результат минимизации вдоль старого направления.

Метод сопряженных направлений: переход от наискорейшего спуска

Нужно заменить обычную ортогональность направлений на ортогональность, согласованную с матрицей A :

$$(p_i, Ap_j) = 0, \quad i \neq j.$$

Именно это условие приводит к методу сопряженных направлений.



Метод сопряженных направлений: вывод условия

Пусть на предыдущем шаге мы уже минимизировали Ψ вдоль направления p_j . Это означает

$$\left. \frac{d}{d\tau} \Psi(x + \tau p_j) \right|_{\tau=0} = (\nabla \Psi(x), p_j) = 0.$$

Теперь сделаем новый шаг вдоль направления p_i :

$$x \leftarrow x + \alpha p_i.$$

Хотим, чтобы минимум вдоль старого направления p_j не испортился:

$$(\nabla \Psi(x + \alpha p_i), p_j) = 0.$$

Но так как для $\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$ при $A = A^\top$ имеем $\nabla \Psi(x) = Ax - b$, то

$$\nabla \Psi(x + \alpha p_i) = A(x + \alpha p_i) - b = Ax - b + \alpha A p_i = \nabla \Psi(x) + \alpha A p_i.$$

Поэтому достаточно потребовать

$$(A p_i, p_j) = 0.$$

То есть новый шаг должен быть ортогонален старому не в обычном, а в A -скалярном произведении.

Метод сопряженных направлений: определение

Векторы $p_0, p_1, \dots, p_m$ называются **A-сопряженными**, если

$$(p_i, Ap_j) = 0, \quad i \neq j.$$

Эквивалентно:

$$(p_i, p_j)_A = 0, \quad i \neq j, \quad (u, v)_A := (Au, v).$$

- Это не обычная ортогональность, а ортогональность в геометрии, задаваемой матрицей A .
- Для функционала энергии

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

такие направления особенно удобны.

- Минимизация вдоль нового A -сопряженного направления не разрушает минимум, найденный вдоль предыдущих направлений.
- Поэтому метод не возвращается к уже исправленным компонентам ошибки.

Метод сопряженных направлений

Пусть построены A -сопряженные направления

$$p_0, p_1, \dots, p_{n-1}.$$

После k шагов приближение ищется среди векторов вида

$$x^{(0)} + \gamma_0 p_0 + \gamma_1 p_1 + \dots + \gamma_{k-1} p_{k-1},$$

то есть среди всех векторов из множества

$$x^{(0)} + \text{Lin}(p_0, \dots, p_{k-1}),$$

где $\text{Lin}(p_0, \dots, p_{k-1})$ — линейная оболочка векторов $p_0, \dots, p_{k-1}$.

На следующем шаге минимизируем Ψ вдоль очередного направления:

$$x^{(k+1)} = x^{(k)} + \alpha_k p_k.$$

Из условия

$$\frac{d}{d\alpha} \Psi(x^{(k)} + \alpha p_k) = 0$$

получаем

$$\alpha_k = -\frac{(r^{(k)}, p_k)}{(Ap_k, p_k)}, \quad r^{(k)} = Ax^{(k)} - b.$$

В точной арифметике при линейной независимости направлений решение находится не более чем за n шагов.

Метод сопряженных градиентов (CG)

Метод сопряженных градиентов (conjugate gradient method – CG) — это частный случай метода сопряженных направлений, в котором направления строятся автоматически по невязкам.

- После шага по $p^{(k)}$ новый антиградиент

$$-r^{(k+1)}$$

указывает направление убывания, но сам по себе не обязан быть A -сопряженным прежнему направлению $p^{(k)}$.

- Поэтому новое направление берут в виде

$$p^{(k+1)} = -r^{(k+1)} + \beta_k p^{(k)}.$$

- Коэффициент β_k выбирают так, чтобы выполнялось условие сопряженности

$$(p^{(k+1)}, Ap^{(k)}) = 0.$$

- Для линейного CG получается формула

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}.$$

Метод сопряженных градиентов (CG): алгоритм

Пусть $A = A^T > 0$. Зададим

$$r^{(0)} = Ax^{(0)} - b, \quad p^{(0)} = -r^{(0)}.$$

Для $k = 0, 1, 2, \dots$:

$$\alpha_k = -\frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})},$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)},$$

$$r^{(k+1)} = r^{(k)} + \alpha_k Ap^{(k)},$$

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})},$$

$$p^{(k+1)} = -r^{(k+1)} + \beta_k p^{(k)}.$$


Метод сопряженных градиентов (CG): геометрическая иллюстрация

Для квадратичного функционала

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

метод сопряженных градиентов строит направления, которые не уничтожают уже сделанное продвижение.

- Наискорейший спуск может долго идти зигзагами.
- Метод сопряженных градиентов использует A -сопряженные направления.
- Поэтому для двумерной квадратичной задачи он может прийти в минимум за два шага.
- В n -мерном случае в точной арифметике нужно не более n шагов.



Метод сопряженных градиентов (CG): свойства

Метод сопряженных градиентов применим к системам

$$Ax = b$$

с симметричной положительно определенной матрицей

$$A = A^T > 0.$$

- В точной арифметике метод находит решение не более чем за n шагов.

- На практике обычно останавливаются раньше:


$$\frac{\|Ax^{(k)} - b\|}{\|b\|} < \varepsilon.$$

- Скорость сходимости зависит от распределения собственных значений.
- Если собственные значения хорошо сгруппированы, метод обычно сходится быстро.
- Плохая обусловленность замедляет сходимость.

Метод сопряженных градиентов (CG): сравнение с градиентным спуском

На плохо обусловленной квадратичной задаче градиентный спуск может долго двигаться по узкому оврагу.

- Обычный градиентный спуск использует только локальное направление антиградиента.
- Метод сопряженных градиентов учитывает геометрию, задаваемую матрицей A .
- Поэтому он обычно требует существенно меньше итераций.



Метод сопряженных градиентов: крыловские подпространства

До сих пор в лекции невязка обозначалась как

$$Ax^{(k)} - b,$$

потому что для функционала энергии она совпадает с градиентом.

В литературе по **крыловским методам** чаще используют обозначение

$$r^{(k)} = b - Ax^{(k)}.$$

Тогда определяют **крыловское подпространство**

$$K_k(A, r^{(0)}) = \text{Lin}\{r^{(0)}, Ar^{(0)}, \dots, A^{k-1}r^{(0)}\}.$$

При таком обозначении метод сопряженных градиентов тоже можно понимать как поиск приближения в множестве

$$x^{(k)} \in x^{(0)} + K_k(A, r^{(0)}).$$

Это описание будет удобно для MINRES, GMRES, BiCG и BiCGSTAB.

Предобуславливание: основная идея

Если матрица A плохо обусловлена, то даже метод сопряженных градиентов может сходиться медленно.


Идея предобуславливания: заменить

систему $Ax = b$ эквивалентной системой $M^{-1}Ax = M^{-1}b$, где M устроена проще, чем A , но приближает ее.

- Нужно, чтобы новая система была лучше обусловлена:

$$\kappa(M^{-1}A) \ll \kappa(A).$$

- При этом системы с матрицей M должны решаться быстро.
- Предобуславливатель меняет геометрию задачи так, чтобы итерационный метод двигался эффективнее.



Предобуславливатель M выбирают так, чтобы

- он был проще, чем A ;
- систему

$$Mz = r$$

можно было решать быстро;

- при этом M в каком-то смысле приближал матрицу A .

Поэтому возникают уже знакомые идеи:

- **Диагональный предобуславливатель**

$$M = \text{diag}(A).$$

Это та же идея, что и в методе Якоби: берем только диагональ.

- **PCG** (Preconditioned Conjugate Gradient) — предобусловленный метод сопряженных градиентов.
- В PCG вместо невязки используют

$$z^{(k)} = M^{-1}r^{(k)}, \quad r^{(k)} = b - Ax^{(k)}.$$

- Для симметричных положительно определенных матриц часто используют неполное разложение Холецкого:

$$M \approx LL^T.$$

- Для несимметричных матриц используют неполное LU-разложение:

$$M \approx LU.$$

- В случае Холецкого отдельный верхний фактор не выписывают, потому что он равен L^T .
- В SciPy есть функция `scipy.sparse.linalg.spilu`, где

$$\text{ILU} = \text{Incomplete LU}.$$

- Отдельной публичной sparse-функции для неполного разложения Холецкого в SciPy сейчас нет.

Предобуславливание: пример ILU в SciPy

В SciPy `spilu` строит приближенное разложение $M \approx LU$.


Для применения предобуславливателя используют оба фактора:

$$Ly = r, \quad Uz = y.$$

На рисунке показаны одна и та же разреженная матрица A , а также точные и неполные факторы L и U . Числа **nnz** – number of nonzeros – в заголовках показывают, что неполные факторы заметно реже точных.

Если число сохраняемых ненулевых элементов в строке ограничено, то построение и применение такого предобуславливателя имеют порядок $O(n)$.

Для плотной матрицы полное LU имеет стоимость $O(n^3)$.



MINRES: симметричная, но не положительно определенная матрица

Метод сопряженных градиентов требует

$$A = A^T > 0.$$

Если матрица симметрична, но не является положительно определенной, то функционал энергии

$$\Psi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

может не иметь минимума.

В этом случае можно минимизировать не функционал энергии, а норму невязки:

$$\|Ax - b\|_2 \rightarrow \min.$$

Метод MINRES ищет приближение в виде

$$x^{(k)} = x^{(0)} + y_0 r^{(0)} + y_1 A r^{(0)} + \dots + y_{k-1} A^{k-1} r^{(0)},$$

то есть

$$x^{(k)} \in x^{(0)} + K_k(A, r^{(0)}), \quad r^{(0)} = b - Ax^{(0)}.$$

Коэффициенты $y_0, \dots, y_{k-1}$ выбирают так, чтобы норма невязки была минимальна.

Если матрица несимметрична, $A \neq A^T$, то методы CG и MINRES в их прежнем виде уже неприменимы: в них существенно использовалась симметрия матрицы.

Метод GMRES сохраняет общую идею крыловских методов: ищем приближение в виде

$$x^{(k)} \in x^{(0)} + K_k(A, r^{(0)}), \quad r^{(0)} = b - Ax^{(0)},$$

где

$$K_k(A, r^{(0)}) = \text{Lin}\{r^{(0)}, Ar^{(0)}, \dots, A^{k-1}r^{(0)}\}.$$

То есть после k шагов рассматриваются все векторы вида

$$x^{(k)} = x^{(0)} + y_0 r^{(0)} + y_1 Ar^{(0)} + \dots + y_{k-1} A^{k-1} r^{(0)}.$$

Из всех векторов выбирается тот, для которого норма невязки минимальна:

$$\|b - Ax^{(k)}\|_2 \rightarrow \min.$$

Иначе говоря, GMRES выбирает лучшую линейную комбинацию векторов

$$r^{(0)}, Ar^{(0)}, \dots, A^{k-1}r^{(0)}$$

по критерию минимальной нормы невязки.

GMRES: отличие от предыдущих методов

- **CG** применим к матрицам

$$A = A^T > 0$$

и использует специальную структуру квадратичной задачи.

- **MINRES** тоже требует симметрию

$$A = A^T,$$

но не требует положительной определенности.

- **GMRES** работает с общей несимметричной матрицей

$$A \neq A^T$$

и на каждом шаге выбирает в текущем крыловском подпространстве вектор с наименьшей нормой невязки.

- Так как

$$K_k(A, r^{(0)}) \subset K_{k+1}(A, r^{(0)}),$$

на каждом следующем шаге выбор делается из более широкого множества.

- Поэтому норма невязки в GMRES по шагам не возрастает.
- Цена за это — нужно хранить все уже построенные базисные векторы текущего крыловского подпространства.

Метод GMRES уже позволяет решать несимметричные системы

$$Ax = b.$$

Но это не единственный возможный путь.

В GMRES каждое новое приближение выбирается из все более широкого крыловского подпространства, поэтому по ходу работы приходится хранить все уже построенные векторы.

Для больших разреженных матриц интересны и другие методы, устроенные ближе по духу к CG: новое приближение в них строится по формулам, использующим лишь небольшое число текущих векторов, а не всю накопленную информацию.

Один из таких методов — метод бисопряженных градиентов, к которому мы сейчас и перейдем.

Метод бисопряженных градиентов: идея

Для несимметричной системы

$$Ax = b$$

метод бисопряженных градиентов (Biconjugate gradient method, BiCG) строит два связанных итерационных процесса: один для матрицы A , другой для матрицы A^T .

Начинаем с невязки

$$r^{(0)} = b - Ax^{(0)}$$

и произвольно выбираем вспомогательный вектор из критерия

$$\tilde{r}^{(0)} \neq 0, \quad (\tilde{r}^{(0)}, r^{(0)}) \neq 0.$$

Затем строятся две последовательности невязок и направлений:

$$r^{(k)}, p^{(k)} \quad \text{и} \quad \tilde{r}^{(k)}, \tilde{p}^{(k)}.$$

Они выбираются так, чтобы выполнялись условия

$$(\tilde{r}^{(i)}, r^{(j)}) = 0, \quad (\tilde{p}^{(i)}, Ap^{(j)}) = 0, \quad i \neq j.$$

Это называется **биортогональностью**: векторы из одной последовательности ортогональны векторам из другой

Метод бисопряженных градиентов: алгоритм

Пусть

$$\begin{aligned}r^{(0)} &= b - Ax^{(0)}, & \tilde{r}^{(0)} &\neq 0, & (\tilde{r}^{(0)}, r^{(0)}) &\neq 0, \\p^{(0)} &= r^{(0)}, & \tilde{p}^{(0)} &= \tilde{r}^{(0)}.\end{aligned}$$

Для $k = 0, 1, 2, \dots$ вычисляем коэффициент шага

$$\alpha_k = \frac{(\tilde{r}^{(k)}, r^{(k)})}{(\tilde{p}^{(k)}, A\tilde{p}^{(k)})}.$$

Он задает шаг вдоль направления $p^{(k)}$:

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}.$$

После этого обновляем невязки:

$$r^{(k+1)} = r^{(k)} - \alpha_k A p^{(k)},$$

$$\tilde{r}^{(k+1)} = \tilde{r}^{(k)} - \alpha_k A^\top \tilde{p}^{(k)}.$$

После обновления невязок вычисляем коэффициент

$$\beta_k = \frac{(\tilde{r}^{(k+1)}, r^{(k+1)})}{(\tilde{r}^{(k)}, r^{(k)})}.$$

Он показывает, какая часть предыдущего направления переносится в новое направление.

Затем строим новые направления:

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)},$$

$$\tilde{p}^{(k+1)} = \tilde{r}^{(k+1)} + \beta_k \tilde{p}^{(k)}.$$

При этом сохраняются условия биортогональности:

$$(\tilde{r}^{(i)}, r^{(j)}) = 0, \quad (\tilde{p}^{(i)}, Ap^{(j)}) = 0, \quad i \neq j.$$

Метод BiCG можно понимать как несимметричный аналог CG.

- Для несимметричных систем он использует две последовательности невязок и направлений.
- В отличие от GMRES, метод не выбирает на каждом шаге вектор с наименьшей нормой невязки.
- Поэтому сходимость может быть нерегулярной.
- Если знаменатели в формулах для α_k или β_k оказываются нулевыми или слишком малыми, шаг невозможно или ненадежно вычислить.
- Требуется умножение не только на A , но и на A^T .

BiCGSTAB — стабилизированный вариант метода BiCG для несимметричных систем $Ax = b$.

В методе BiCG невязка может убывать нерегулярно: после хорошего шага возможен заметный всплеск.

В BiCGSTAB к шагу типа BiCG добавляется дополнительная коррекция.

Одна итерация устроена так:

- сначала строится направление $p^{(k)}$ и выполняется шаг, похожий на шаг BiCG;
- после этого вычисляется промежуточная невязка

$$s^{(k)};$$

- затем вдоль вектора $s^{(k)}$ делается еще одна коррекция с коэффициентом

$$\omega_k;$$

- эта коррекция подбирается так, чтобы сделать новую невязку как можно меньше.

В стандартной реализации метод не требует умножений на A^T .

Задаем начальное приближение $x^{(0)}$ и начальную невязку $r^{(0)} = b - Ax^{(0)}$.

Выбираем фиксированный вспомогательный вектор

$$\tilde{r}^{(0)}, \quad (\tilde{r}^{(0)}, r^{(0)}) \neq 0.$$

Начальная инициализация:

$$p^{(0)} = r^{(0)}, \quad \rho_0 = (\tilde{r}^{(0)}, r^{(0)}).$$

Для $k = 0, 1, 2, \dots$ выполняем:

$$v^{(k)} = Ap^{(k)}, \quad \alpha_k = \frac{\rho_k}{(\tilde{r}^{(0)}, v^{(k)})},$$

$$s^{(k)} = r^{(k)} - \alpha_k v^{(k)},$$

$$t^{(k)} = As^{(k)}, \quad \omega_k = \frac{(t^{(k)}, s^{(k)})}{(t^{(k)}, t^{(k)})},$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} + \omega_k s^{(k)},$$

$$r^{(k+1)} = s^{(k)} - \omega_k t^{(k)}.$$

После обновления невязки вычисляем

$$\rho_{k+1} = (\tilde{r}^{(0)}, r^{(k+1)}).$$

Затем находим коэффициент

$$\beta_{k+1} = \frac{\rho_{k+1}}{\rho_k} \frac{\alpha_k}{\omega_k}$$

и обновляем направление:

$$p^{(k+1)} = r^{(k+1)} + \beta_{k+1}(p^{(k)} - \omega_k v^{(k)}).$$

Таким образом, одна итерация состоит из двух частей:

- шаг вдоль основного направления

$$p^{(k)};$$

- дополнительная коррекция вдоль промежуточной невязки

$$s^{(k)}.$$

Именно эта вторая часть обычно делает поведение невязки более гладким, чем в BiCG.

BiCGSTAB: как понимать эти формулы

В формулах предыдущего слайда:

- $p^{(k)}$ — основное направление шага;
- $v^{(k)} = Ap^{(k)}$ — образ этого направления под действием матрицы A ;
- α_k — коэффициент шага вдоль $p^{(k)}$;
- $s^{(k)}$ — невязка после этого первого шага;
- $t^{(k)} = As^{(k)}$ — образ промежуточной невязки;
- ω_k — коэффициент дополнительной коррекции вдоль $s^{(k)}$.

То есть одна итерация BiCGSTAB состоит из двух частей:

- шаг типа BiCG:

$$x^{(k)} \rightarrow x^{(k)} + \alpha_k p^{(k)};$$

- стабилизирующая коррекция:

$$x^{(k)} + \alpha_k p^{(k)} \rightarrow x^{(k)} + \alpha_k p^{(k)} + \omega_k s^{(k)}.$$


Именно эта вторая часть обычно делает поведение невязки более гладким.

BiCGSTAB: зачем нужна стабилизация

У BiCG невязка может вести себя нерегулярно: убывание может чередоваться со всплесками.

BiCGSTAB добавляет стабилизирующий шаг, поэтому часто дает более гладкую сходимость.

- BiCGSTAB обычно устойчивее BiCG на практике.
- Но универсальной гарантии быстрой сходимости нет.
- Результат сильно зависит от матрицы и предобуславливателя.




GMRES и BiCGSTAB: сравнение на примере

Оба метода применимы к несимметричным системам $Ax = b$.

- GMRES на каждом шаге минимизирует норму невязки, но требует хранить все уже построенные векторы текущего крыловского подпространства.
- BiCGSTAB не минимизирует невязку на каждом шаге, но использует более компактную итерационную схему.

На рисунке показан **один конкретный пример**, в котором BiCGSTAB сошелся быстрее GMRES. Это не означает, что BiCGSTAB вообще лучше: универсального лидера здесь нет.



Крыловские методы: общая картина

Многие нестационарные методы строят поправку к начальному приближению в крыловском подпространстве:

$$K_k(A, r^{(0)}) = \text{Lin}\{r^{(0)}, Ar^{(0)}, \dots, A^{k-1}r^{(0)}\}, \quad r^{(0)} = b - Ax^{(0)}.$$

То есть

$$x^{(k)} \in x^{(0)} + K_k(A, r^{(0)}).$$

Итого:

- CG минимизирует ошибку в энергетической норме для

$$A = A^T > 0;$$

- MINRES минимизирует невязку для симметричных матриц;
- GMRES минимизирует невязку для несимметричных матриц;
- BiCG использует две связанные последовательности для A и A^T ;
- BiCGSTAB строится на той же идее, но добавляет стабилизирующую коррекцию.

Сравнительная таблица с методами

Тип матрицы	Метод
$A = A^T > 0$	CG, PCG
$A = A^T$, не обязательно $A > 0$	MINRES
$A \neq A^T$	GMRES, BiCG, BiCGSTAB

- CG использует A -сопряженные направления.
- PCG ускоряет CG с помощью предобуславливателя.
- MINRES и GMRES минимизируют норму невязки.
- BiCG и BiCGSTAB применяются к несимметричным системам и строят новое приближение без хранения всей накопленной последовательности векторов.

Методы 2-го порядка: основная идея

До сих пор мы использовали методы 1-го порядка: они строят шаг по значению функции и её градиенту.

В **методах 2-го порядка** дополнительно используют матрицу вторых производных

$$H(x) = \nabla^2 f(x),$$

которую называют **гессианом**.

В точке $x^{(k)}$ функцию заменяют локальной квадратичной моделью:

$$f(x^{(k)} + p) \approx f(x^{(k)}) + (\nabla f(x^{(k)}), p) + \frac{1}{2}(H(x^{(k)})p, p).$$

Минимум этой квадратичной модели достигается в направлении $p^{(k)}$, которое находится из линейной системы

$$H(x^{(k)}) p^{(k)} = -\nabla f(x^{(k)}).$$

После этого делают шаг

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}.$$

То есть на каждом шаге метод 2-го порядка сводит задачу оптимизации к решению линейной системы.

Методы 2-го порядка: плюсы и минусы

Плюсы:

- обычно требуется меньше итераций;
- вблизи минимума сходимость часто намного быстрее, чем у методов 1-го порядка.

Минусы:

- нужно вычислять или приближать гессиан;
- на каждом шаге требуется решать линейную систему;
- одна итерация заметно дороже, особенно в больших размерностях.

Методы 2-го порядка: примеры

- **Метод Ньютона** — использует точный гессиан $H(x^{(k)})$ и на каждом шаге решает линейную систему $H(x^{(k)}) p^{(k)} = -\nabla f(x^{(k)})$, после чего делает шаг

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}.$$

- **Демпфированный метод Ньютона / trust-region методы** — ограничивают шаг, чтобы сделать метод устойчивее вдали от минимума.
- **Квазиньютоновские методы (BFGS, L-BFGS)** — не вычисляют точный гессиан, а строят его приближение по информации о предыдущих шагах.
- **Метод Гаусса–Ньютона** — специальный метод для задач наименьших квадратов $\min \frac{1}{2} \|F(x)\|_2^2$, в котором гессиан приближенно заменяют матрицей

$$J(x)^T J(x),$$

где $J(x)$ — якобиан вектора невязок $F(x)$.

- **Метод Левенберга–Марквардта** — модификация для задач наименьших квадратов и подбора параметров модели по данным; сочетает идею Гаусса–Ньютона с демпфированием шага.

Задача 7

Решить краевую задачу

$$\begin{aligned}-u''(t) + (1+t)u(t) &= (\pi^2 + 1 + t)\sin(\pi t), \quad 0 < t < 1, \\ u(0) &= 0, \quad u(1) = 0.\end{aligned}$$

Точное решение:

$$u_*(t) = \sin(\pi t).$$

Для равномерной сетки

$$t_i = ih, \quad i = 0, 1, \dots, n+1, \quad h = \frac{1}{n+1},$$

построить разностный аналог задачи:

$$\begin{aligned}-\frac{x_{i-1} - 2x_i + x_{i+1}}{h^2} + (1+t_i)x_i &= (\pi^2 + 1 + t_i)\sin(\pi t_i), \quad i = 1, \dots, n, \\ x_0 &= 0, \quad x_{n+1} = 0.\end{aligned}$$

Полученную систему записать в виде

$$Ax = b.$$

Показать, что матрица A симметрична и положительно определена.

Задача 7

Для системы $Ax = b$ реализовать и сравнить следующие методы:

- метод градиентного спуска с постоянным шагом

$$x^{(k+1)} = x^{(k)} - \tau(Ax^{(k)} - b);$$

- метод наискорейшего градиентного спуска

$$x^{(k+1)} = x^{(k)} - \tau_k r^{(k)}, \quad r^{(k)} = Ax^{(k)} - b, \quad \tau_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})};$$

- метод сопряженных градиентов.

Остановить итерации при условии

$$\frac{\|Ax^{(k)} - b\|_2}{\|b\|_2} < 10^{-8}.$$

Для $n = 50, 100, 200, 400$ сравнить число итераций, время счета и ошибку

$$\max_i |x_i - u_*(t_i)|.$$

Для каждой сетки оценить число обусловленности

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

и объяснить, как рост $\kappa(A)$ влияет на число итераций.

Шарый С. П.: Курс ВЫЧИСЛИТЕЛЬНЫХ МЕТОДОВ

Wikipedia: Biconjugate gradient method

Netlib Templates

[Стохастический градиентный спуск](#)